

LAPORAN HASIL DATA ANALYST

Nama Perusahaan : IMDb Top 5000 Movies by Tiago Adria Nunes
Nama Data Analyst : Rifa Sadiqa
NPM : 11122270
Jenjang/Program Studi : S1/Sistem Informasi
Tanggal Laporan : 05 Juni 2026

Laporan Hasil Data Analyst ini Dibuat
Dalam Rangka Bukti Portofolio sebagai Data Analyst

DAFTAR ISI

DAFTAR ISI.....	2
1. PENDAHULUAN.....	3
1.1 Latar Belakang.....	3
1.2 Tujuan Analisis.....	4
2. IDENTIFIKASI KEBUTUHAN BISNIS.....	5
2.1 Permasalahan yang Ditemukan.....	5
2.2. Identifikasi Kebutuhan Bisnis.....	6
3. PENGUMPULAN & PERSIAPAN DATA	8
3.1 Sumber Data	8
3.2 Proses Praproses	10
4. ANALISIS DATA	20
4.1 Eksplorasi Variabel Utama	20
4.2 Visualisasi Data	25
5. TEMUAN & INSIGHT	33
6. PELUANG BISNIS.....	36
7. KESIMPULAN DAN REKOMENDASI.....	38
DAFTAR PUSTAKA	41
LAMPIRAN-LAMPIRAN.....	42

1. PENDAHULUAN

1.1 Latar Belakang

Industri film menghasilkan data yang besar dan beragam. Data tersebut memuat informasi tentang judul film, tahun rilis, genre, sutradara, penulis, durasi, rating, dan jumlah penilaian pengguna. Data film dapat dianalisis untuk memahami karakteristik film, pola popularitas, serta kecenderungan penilaian pengguna. Analisis data film juga dapat membantu perusahaan hiburan, platform streaming, dan penyedia katalog film dalam menyusun strategi promosi, kurasi film, serta sistem rekomendasi berbasis data.

IMDb atau Internet Movie Database merupakan salah satu sumber informasi film, acara televisi, dan film hiburan yang banyak digunakan oleh pengguna. IMDb menyediakan informasi tentang film, rating, ulasan, pemeran, serta data produksi yang dapat membantu pengguna dalam menemukan dan memilih tontonan. IMDb (2026) menyatakan bahwa IMDb merupakan salah satu sumber informasi populer dan otoritatif mengenai film, acara televisi, dan selebritas. Oleh karena itu, data IMDb dapat digunakan sebagai objek analisis untuk memahami karakteristik film berdasarkan rating, jumlah votes, genre, tahun rilis, sutradara, dan penulis.



Gambar 1. Logo IMDb
Sumber: (IMDb Developer, 2026)

IMDb juga menyediakan sebagian data untuk penggunaan personal dan non-komersial. IMDb Developer (2026) menjelaskan bahwa subset data IMDb dapat diakses dan digunakan untuk kepentingan personal serta non-komersial. Selain itu, dataset Top 5000 IMDb juga tersedia dalam bentuk dataset publik di Kaggle. (Nunes, 2026) menjelaskan bahwa dataset IMDb Top 5000 Movies berisi informasi mengenai 5.000 film dengan atribut seperti judul, tahun rilis, rating rata-rata, jumlah votes, durasi, genre, sutradara, penulis, dan tautan IMDb.

Laporan ini menggunakan dataset **Top 5000 IMDb** sebagai objek analisis. Dataset ini memuat 5.000 data film dengan beberapa atribut utama, yaitu `tconst`, `primaryTitle`, `startYear`, `rank`, `averageRating`, `numVotes`, `runtimeMinutes`, `directors`, `writers`, dan `genres`. Atribut tersebut dipilih karena setiap atribut dapat mendukung

proses analisis film. Kolom genres dapat digunakan untuk mengetahui genre film yang paling banyak muncul. Kolom startYear dapat digunakan untuk melihat tren jumlah film berdasarkan tahun rilis. Kolom averageRating dan numVotes dapat digunakan untuk menganalisis hubungan antara kualitas penilaian dan popularitas film.

Analisis data dalam laporan ini dilakukan melalui beberapa tahap. Tahap pertama adalah pengumpulan data. Tahap kedua adalah telaah data untuk memahami struktur dataset. Tahap ketiga adalah validasi data untuk memeriksa kelengkapan data, duplikasi, tipe data, dan outlier. Tahap keempat adalah penentuan objek data melalui pemilihan atribut dan record yang relevan. Tahap kelima adalah visualisasi data menggunakan Google Looker Studio. Google Colaboratory digunakan untuk praproses data dan pembentukan dataset objek analisis. Google Looker Studio digunakan untuk menampilkan visualisasi business intelligence.

Hasil analisis ini diharapkan dapat memberikan insight mengenai karakteristik film dalam dataset IMDb. Insight tersebut mencakup genre film yang dominan, tren jumlah film berdasarkan tahun rilis, hubungan rating IMDb dengan jumlah votes, serta komposisi film berdasarkan kategori rating. Hasil analisis ini juga dapat digunakan sebagai dasar rekomendasi bisnis, khususnya dalam strategi pengelolaan katalog film, promosi film, dan pengembangan sistem rekomendasi film berbasis data.

1.2 Tujuan Analisis

- Mengetahui karakteristik film dalam dataset Top 5000 IMDb berdasarkan genre, tahun rilis, rating, jumlah votes, durasi, sutradara, dan penulis.
- Menganalisis genre film yang memiliki jumlah kemunculan terbanyak dalam dataset.
- Menganalisis tren jumlah film berdasarkan tahun rilis.
- Menganalisis hubungan antara rating IMDb dan jumlah votes.
- Mengetahui komposisi film berdasarkan kategori rating.
- Menemukan insight dan rekomendasi bisnis untuk strategi pengelolaan katalog film, promosi film, dan sistem rekomendasi film.

2. IDENTIFIKASI KEBUTUHAN BISNIS

2.1 Permasalahan yang Ditemukan

Dataset Top 5000 IMDb memuat informasi film yang dapat digunakan untuk mendukung analisis bisnis dalam bidang hiburan digital. Dataset ini menyediakan atribut seperti judul film, tahun rilis, genre, rating, jumlah votes, durasi, sutradara, dan penulis. Namun, data tersebut belum dapat langsung menghasilkan insight bisnis apabila belum melalui proses telaah data, validasi data, penentuan objek data, dan visualisasi data.

Permasalahan pertama adalah informasi film dalam dataset masih perlu diolah agar dapat digunakan untuk menjawab kebutuhan bisnis. Data mentah hanya menampilkan daftar film dan atributnya. Data tersebut belum menunjukkan genre yang paling dominan, pola jumlah film berdasarkan tahun rilis, hubungan antara rating dan jumlah votes, serta komposisi film berdasarkan kategori rating. Oleh karena itu, proses analisis diperlukan agar data dapat menghasilkan informasi yang berguna untuk strategi pengelolaan katalog film dan rekomendasi film.

Permasalahan kedua adalah beberapa kolom kategorikal memuat lebih dari satu nilai dalam satu kolom. Kolom genres, directors, dan writers dapat berisi beberapa nama atau kategori dalam satu baris. Kondisi tersebut dapat menyulitkan proses visualisasi di Google Looker Studio karena sistem dapat membaca gabungan nilai sebagai satu kategori. Oleh karena itu, data perlu disusun ulang menjadi format yang lebih sesuai untuk kebutuhan visualisasi, yaitu dengan memisahkan atribut menjadi kolom `attribute_type` dan `attribute_name`.

Permasalahan ketiga adalah dataset masih memiliki nilai kosong pada kolom writers. Nilai kosong tersebut perlu ditangani agar proses analisis tidak terganggu. Dalam proses validasi data, nilai kosong pada kolom writers diisi dengan nilai pengganti agar struktur dataset tetap lengkap dan dapat digunakan untuk analisis selanjutnya.

Permasalahan keempat adalah dataset memiliki nilai outlier pada beberapa kolom numerik. Outlier ditemukan pada kolom `averageRating` dan `runtimeMinutes`. Namun, outlier tersebut tidak langsung dihapus karena masih memiliki makna dalam konteks film. Film dengan rating sangat tinggi dapat menunjukkan film berkualitas, sedangkan film dengan durasi sangat pendek atau panjang masih dapat terjadi pada film pendek, TV special, animasi pendek, atau film epik berdurasi panjang.

Permasalahan kelima adalah rating film tidak cukup digunakan sebagai satu-satunya dasar rekomendasi. Film dengan rating tinggi belum tentu memiliki jumlah votes yang besar. Sebaliknya, film dengan jumlah votes besar dapat menunjukkan tingkat popularitas yang tinggi. Oleh karena itu, analisis perlu mempertimbangkan kombinasi antara `averageRating` dan `numVotes` agar rekomendasi film lebih akurat dan tidak bias.

Berdasarkan permasalahan tersebut, analisis data diperlukan untuk menghasilkan insight yang dapat membantu pengambilan keputusan bisnis. Insight yang diharapkan meliputi genre film yang paling dominan, tren jumlah film berdasarkan tahun rilis, hubungan antara rating IMDb dan jumlah votes, serta komposisi film berdasarkan kategori rating. Hasil analisis tersebut dapat digunakan untuk mendukung strategi promosi film, pengelolaan katalog film, dan pengembangan sistem rekomendasi film berbasis data.

2.2. Identifikasi Kebutuhan Bisnis

Berdasarkan permasalahan yang ditemukan, analisis dataset Top 5000 IMDb perlu diarahkan untuk menghasilkan informasi yang dapat membantu pengambilan keputusan bisnis dalam bidang hiburan digital. Platform film atau penyedia katalog film membutuhkan informasi yang jelas tentang jenis film yang dominan, perkembangan jumlah film berdasarkan tahun rilis, hubungan antara rating dan jumlah votes, serta komposisi film berdasarkan kategori rating.

Masalah bisnis yang ditemukan adalah perusahaan perlu mengetahui karakteristik film yang berpotensi menarik perhatian pengguna. Perusahaan tidak cukup hanya melihat daftar film secara umum. Perusahaan perlu memahami genre yang paling banyak muncul, pola tahun rilis film, tingkat popularitas film berdasarkan jumlah votes, dan kategori rating film. Informasi tersebut dapat digunakan untuk mendukung strategi promosi, pengelolaan katalog film, dan penyusunan rekomendasi film.

Peluang bisnis yang ditemukan adalah platform film dapat menggunakan hasil analisis untuk menentukan prioritas film. Platform film dapat mempromosikan genre yang paling dominan, menampilkan film dengan rating dan jumlah votes tinggi, serta mengelompokkan film berdasarkan kategori rating. Dengan cara tersebut, platform film dapat menyusun katalog yang lebih terarah dan memberikan rekomendasi film yang lebih sesuai dengan minat pengguna.

Berdasarkan kebutuhan bisnis tersebut, pertanyaan utama analisis dalam laporan ini adalah sebagai berikut.

1. Genre film apa yang memiliki jumlah kemunculan terbanyak dalam dataset Top 5000 IMDb?
2. Bagaimana tren jumlah film berdasarkan tahun rilis dalam dataset Top 5000 IMDb?
3. Bagaimana hubungan antara rating IMDb dan jumlah votes pada film?
4. Bagaimana komposisi film berdasarkan kategori rating tinggi, sedang, dan rendah?

Pertanyaan analisis tersebut dipilih karena setiap pertanyaan dapat membantu perusahaan memahami pola film, popularitas film, dan peluang rekomendasi berbasis data. Hasil dari pertanyaan tersebut diharapkan dapat mendukung pengambilan keputusan bisnis dalam strategi promosi film, pengelolaan katalog film, dan pengembangan sistem rekomendasi film.

3. PENGUMPULAN & PERSIAPAN DATA

3.1 Sumber Data

Data yang digunakan dalam laporan ini adalah dataset **Top 5000 IMDb**. Dataset ini diperoleh dari situs data publik Kaggle dalam format CSV. Dataset ini memuat informasi mengenai film yang tersedia pada IMDb, seperti judul film, tahun rilis, peringkat, rating, jumlah votes, durasi film, sutradara, penulis, genre, dan tautan IMDb.

Tabel 3.1. Sumber Data

No	Sumber Data	Keterangan
1	Dataset	Top 5000 IMDb Movies. Dataset ini diperoleh dari situs data publik Kaggle: https://www.kaggle.com/datasets/tiagoadrianunes/imdb-top-5000-movies diakses pada tanggal: 04 Juni 2026
2	Format Data	CSV
3	Jumlah Data	Dataset memiliki 5.000 baris dan 12 kolom.
4	Tools Pengolahan Data	Google Colaboratory dengan bahasa pemrograman Python.
5	Library Python	Pandas, NumPy, Seaborn, dan Matplotlib.
6	Tools Visualisasi	Google Looker Studio.

Dataset Top 5000 IMDb digunakan karena dataset ini memiliki atribut yang sesuai dengan kebutuhan analisis. Dataset ini dapat digunakan untuk menganalisis genre film yang paling banyak muncul, tren jumlah film berdasarkan tahun rilis, hubungan antara rating IMDb dan jumlah votes, serta komposisi film berdasarkan kategori rating. Dataset ini juga dapat digunakan untuk mendukung penyusunan insight dan rekomendasi bisnis dalam pengelolaan katalog film dan strategi rekomendasi film.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W
1	tconst	primaryTitle	startYear	rank	averageRating	numVotes	runtimeMinutes	directors	writers	genres	IMDbLink	Title_IMDb_Link											
2	tt0111161	The Shawshank Redemption	1994	1	8.3	1391341	142	Frank Darabont	Stephen King	Drama	https://www.imdb.com/title/tt0111161/	target=""	blank=""	tt0111161/	target=""	blank=""	tt0111161/	target=""	blank=""	tt0111161/	target=""	blank=""	tt0111161/
3	tt0068646	The Godfather	1972	2	8.9	2228974	175	Francis Ford Coppola	Mario Puzo, Francis Ford Coppola	Crime, Drama	https://www.imdb.com/title/tt0068646/	target=""	blank=""	tt0068646/	target=""	blank=""	tt0068646/	target=""	blank=""	tt0068646/	target=""	blank=""	tt0068646/
4	tt0468569	The Dark Knight	2008	3	9.1	13173646	152	Christopher Nolan	David S. Goyer, Jonathan Nolan, Christopher Nolan, Bob Kane	Crime, Thriller	https://www.imdb.com/title/tt0468569/	target=""	blank=""	tt0468569/	target=""	blank=""	tt0468569/	target=""	blank=""	tt0468569/	target=""	blank=""	tt0468569/
5	tt0167260	The Lord of the Rings: The Return of the King	2003	4	9.2	2166974	201	Peter Jackson	Philippa Boyens, Fran Walsh, Peter Jackson, J.R.R. Tolkien	Adventure, Drama, Fantasy	https://www.imdb.com/title/tt0167260/	target=""	blank=""	tt0167260/	target=""	blank=""	tt0167260/	target=""	blank=""	tt0167260/	target=""	blank=""	tt0167260/
6	tt0108052	Schindler's List	1993	5	9.3	1586572	195	Steven Spielberg	Thomas Keneally, Steven Zaillian	Biography, Drama, History	https://www.imdb.com/title/tt0108052/	target=""	blank=""	tt0108052/	target=""	blank=""	tt0108052/	target=""	blank=""	tt0108052/	target=""	blank=""	tt0108052/
7	tt0071562	The Godfather Part II	1974	6	8.9	1496337	202	Francis Ford Coppola	Mario Puzo, Francis Ford Coppola	Crime, Drama	https://www.imdb.com/title/tt0071562/	target=""	blank=""	tt0071562/	target=""	blank=""	tt0071562/	target=""	blank=""	tt0071562/	target=""	blank=""	tt0071562/
8	tt0050083	12 Angry Men	1957	7	9.8	98521	96	Sidney Lumet	Reginald Rose	Crime, Drama	https://www.imdb.com/title/tt0050083/	target=""	blank=""	tt0050083/	target=""	blank=""	tt0050083/	target=""	blank=""	tt0050083/	target=""	blank=""	tt0050083/
9	tt0120737	The Lord of the Rings: The Fellowship of the Ring	2001	8	8.9	2209192	178	Peter Jackson	J.R.R. Tolkien, Peter Jackson, Philippa Boyens, Fran Walsh	Adventure, Drama, Fantasy	https://www.imdb.com/title/tt0120737/	target=""	blank=""	tt0120737/	target=""	blank=""	tt0120737/	target=""	blank=""	tt0120737/	target=""	blank=""	tt0120737/
10	tt1375666	Inception	2010	9	8.8	2821979	148	Christopher Nolan	Christopher Nolan	Adventure, Sci-Fi, Thriller	https://www.imdb.com/title/tt1375666/	target=""	blank=""	tt1375666/	target=""	blank=""	tt1375666/	target=""	blank=""	tt1375666/	target=""	blank=""	tt1375666/
11	tt0137523	Fight Club	1999	10	8.8	2613469	139	Chuck Palahniuk, Jim Uhls	Chuck Palahniuk, Jim Uhls	Crime, Drama, Thriller	https://www.imdb.com/title/tt0137523/	target=""	blank=""	tt0137523/	target=""	blank=""	tt0137523/	target=""	blank=""	tt0137523/	target=""	blank=""	tt0137523/
12	tt0109830	Forrest Gump	1994	11	8.8	2499765	142	Robert Zemeckis	Winston Groom, Eric Roth	Drama, Romance	https://www.imdb.com/title/tt0109830/	target=""	blank=""	tt0109830/	target=""	blank=""	tt0109830/	target=""	blank=""	tt0109830/	target=""	blank=""	tt0109830/
13	tt0110912	Pulp Fiction	1994	12	8.8	2438216	154	Quentin Tarantino	Roger Avary, Quentin Tarantino	Crime, Drama	https://www.imdb.com/title/tt0110912/	target=""	blank=""	tt0110912/	target=""	blank=""	tt0110912/	target=""	blank=""	tt0110912/	target=""	blank=""	tt0110912/
14	tt0167261	The Lord of the Rings: The Two Towers	2002	13	8.8	1959520	179	Peter Jackson	J.R.R. Tolkien, Stephen Sinclair, Peter Jackson, Philippa Boyens, Fran Walsh	Adventure, Drama, Fantasy	https://www.imdb.com/title/tt0167261/	target=""	blank=""	tt0167261/	target=""	blank=""	tt0167261/	target=""	blank=""	tt0167261/	target=""	blank=""	tt0167261/
15	tt0060196	The Good, the Bad and the Ugly	1966	14	8.8	891493	178	Sergio Leone	Mickey Knox, Luciano Vincenzoni, Furio Scarpelli, Agenore Incrocci, Sergio Leone	Adventure, Drama, Western	https://www.imdb.com/title/tt0060196/	target=""	blank=""	tt0060196/	target=""	blank=""	tt0060196/	target=""	blank=""	tt0060196/	target=""	blank=""	tt0060196/
16	tt0816692	Interstellar	2014	15	8.7	2537875	169	Christopher Nolan	Jonathan Nolan, Christopher Nolan	Adventure, Drama, Sci-Fi	https://www.imdb.com/title/tt0816692/	target=""	blank=""	tt0816692/	target=""	blank=""	tt0816692/	target=""	blank=""	tt0816692/	target=""	blank=""	tt0816692/
17	tt0133093	The Matrix	1999	16	8.7	2250969	136	Lana Wachowski, Lilly Wachowski	Lilly Wachowski, Lana Wachowski	Action, Sci-Fi	https://www.imdb.com/title/tt0133093/	target=""	blank=""	tt0133093/	target=""	blank=""	tt0133093/	target=""	blank=""	tt0133093/	target=""	blank=""	tt0133093/
18	tt0080684	Star Wars: Episode V - The Empire Strikes Back	1980	17	8.7	1506758	124	Irvin Kershner	Lawrence Kasdan, George Lucas, Leigh Brackett	Adventure, Fantasy, Sci-Fi	https://www.imdb.com/title/tt0080684/	target=""	blank=""	tt0080684/	target=""	blank=""	tt0080684/	target=""	blank=""	tt0080684/	target=""	blank=""	tt0080684/
19	tt0099685	GoodFellas	1990	18	8.7	1393813	145	Martin Scorsese	Martin Scorsese, Nicholas Pileggi	Biography, Crime, Drama	https://www.imdb.com/title/tt0099685/	target=""	blank=""	tt0099685/	target=""	blank=""	tt0099685/	target=""	blank=""	tt0099685/	target=""	blank=""	tt0099685/
20	tt0114369	Seven	1995	19	8.6	2025035	127	David Fincher	Andrew Kevin Walker	Crime, Drama, Mystery	https://www.imdb.com/title/tt0114369/	target=""	blank=""	tt0114369/	target=""	blank=""	tt0114369/	target=""	blank=""	tt0114369/	target=""	blank=""	tt0114369/
21	tt0102926	The Silence of the Lambs	1991	20	8.6	1725713	118	Jonathan Demme	Thomas Harris, Ted Tally	Crime, Drama, Horror	https://www.imdb.com/title/tt0102926/	target=""	blank=""	tt0102926/	target=""	blank=""	tt0102926/	target=""	blank=""	tt0102926/	target=""	blank=""	tt0102926/
22	tt0120815	Saving Private Ryan	1998	21	8.6	1641909	169	Steven Spielberg	Robert Rodat	Drama, War	https://www.imdb.com/title/tt0120815/	target=""	blank=""	tt0120815/	target=""	blank=""	tt0120815/	target=""	blank=""	tt0120815/	target=""	blank=""	tt0120815/
23	tt0076750	Star Wars: Episode IV - A New Hope	1977	22	8.6	1572159	121	George Lucas	George Lucas	Adventure, Fantasy, Sci-Fi	https://www.imdb.com/title/tt0076750/	target=""	blank=""	tt0076750/	target=""	blank=""	tt0076750/	target=""	blank=""	tt0076750/	target=""	blank=""	tt0076750/
24	tt0120689	The Green Mile	1999	23	8.6	1561348	189	Frank Darabont	Stephen King, Frank Darabont	Crime, Drama, Fantasy	https://www.imdb.com/title/tt0120689/	target=""	blank=""	tt0120689/	target=""	blank=""	tt0120689/	target=""	blank=""	tt0120689/	target=""	blank=""	tt0120689/
25	tt0103064	Terminator 2: Judgment Day	1991	24	8.6	1285410	137	James Cameron	William Wisher, James Cameron	Action, Adventure, Sci-Fi	https://www.imdb.com/title/tt0103064/	target=""	blank=""	tt0103064/	target=""	blank=""	tt0103064/	target=""	blank=""	tt0103064/	target=""	blank=""	tt0103064/
26	tt0073486	One Flew Over the Cuckoo's Nest	1975	25	8.6	1157483	133	Miloš Forman	Dale Wasserman, Bo Goldman, Ken Kesey, Lawrence Hauben	Drama	https://www.imdb.com/title/tt0073486/	target=""	blank=""	tt0073486/	target=""	blank=""	tt0073486/	target=""	blank=""	tt0073486/	target=""	blank=""	tt0073486/
27	tt0345439	The Incredibles	2003	26	8.6	606303	134	Brad Pitt	Robert Rodriguez	Adventure, Animation, Comedy	https://www.imdb.com/title/tt0345439/	target=""	blank=""	tt0345439/	target=""	blank=""	tt0345439/	target=""	blank=""	tt0345439/	target=""	blank=""	tt0345439/
28	tt0073486	One Flew Over the Cuckoo's Nest	1975	25	8.6	1157483	133	Miloš Forman	Dale Wasserman, Bo Goldman, Ken Kesey, Lawrence Hauben	Drama	https://www.imdb.com/title/tt0073486/	target=""	blank=""	tt0073486/	target=""	blank=""	tt0073486/	target=""	blank=""	tt0073486/	target=""	blank=""	tt0073486/

Gambar 3.1. Tampilan Dataset Top 5000 IMDb

Kolom-kolom dalam dataset perlu dipahami terlebih dahulu sebelum proses analisis dilakukan. Pemahaman terhadap kolom data membantu analisis menentukan fitur yang relevan, memahami tipe informasi yang tersedia, dan memilih metode analisis yang tepat.

Tabel 3.2. Keterangan Kolom Dataset Top 5000 IMDb

No	Nama Kolom	Keterangan
1	tconst	Kode unik film pada IMDb. Kolom ini digunakan sebagai identitas unik untuk setiap film.
2	primaryTitle	Judul utama film. Kolom ini digunakan untuk mengidentifikasi nama film.
3	startYear	Tahun rilis film. Kolom ini digunakan untuk menganalisis tren jumlah film berdasarkan tahun rilis.
4	rank	Urutan atau peringkat film dalam dataset. Kolom ini menunjukkan posisi film dalam daftar Top 5000 IMDb.
5	averageRating	Nilai rata-rata rating film. Kolom ini digunakan untuk melihat kualitas penilaian film berdasarkan rating IMDb.
6	numVotes	Jumlah votes atau jumlah penilaian pengguna. Kolom ini digunakan untuk mengukur tingkat popularitas film.

7	runtimeMinutes	Durasi film dalam satuan menit. Kolom ini digunakan untuk mengetahui panjang durasi film.
8	directors	Nama sutradara film. Kolom ini digunakan untuk mengetahui pihak yang menyutradarai film.
9	writers	Nama penulis film. Kolom ini digunakan untuk mengetahui pihak yang menulis cerita atau naskah film.
10	genres	Genre film. Kolom ini digunakan untuk menganalisis kategori film yang paling banyak muncul.
11	IMDbLink	Tautan halaman film pada IMDb. Kolom ini berfungsi sebagai referensi, bukan sebagai fitur analisis utama.
12	Title_IMDb_Link	Tautan IMDb yang terhubung dengan judul film. Kolom ini berfungsi sebagai referensi tambahan, bukan sebagai fitur analisis utama.

Berdasarkan struktur dataset tersebut, data memiliki kombinasi kolom numerik dan kategorikal. Kolom numerik meliputi startYear, rank, averageRating, numVotes, dan runtimeMinutes. Kolom kategorikal meliputi tconst, primaryTitle, directors, writers, genres, IMDbLink, dan Title_IMDb_Link. Kombinasi kedua jenis kolom tersebut memungkinkan dataset digunakan untuk analisis deskriptif, validasi data, korelasi fitur numerik, serta visualisasi business intelligence.

Data dimuat ke dalam Google Colaboratory menggunakan Python. Library pandas digunakan untuk membaca dan mengolah dataset. Library numpy digunakan untuk mendukung proses komputasi numerik. Library seaborn dan matplotlib digunakan untuk membuat visualisasi awal pada tahap eksplorasi dan validasi data. Google Looker Studio digunakan untuk membuat visualisasi akhir dalam bentuk dashboard.

3.2 Proses Praproses

Proses praproses data dalam laporan ini dilakukan untuk memastikan bahwa dataset Top 5000 IMDb siap digunakan dalam analisis. Proses praproses mencakup tahap menelaah data, memeriksa informasi dasar dataset, memeriksa missing value, membersihkan data kosong, memeriksa duplikasi data, memvalidasi tipe data, dan memeriksa outlier pada kolom numerik. Proses ini dilakukan menggunakan Google Colaboratory dengan bahasa pemrograman Python.

Tabel 3.3. Ringkasan Proses Praproses Data

No	Tahap Praproses	Tujuan	Hasil
1	Load dataset	Memuat dataset Top 5000 IMDb ke dalam Google Colaboratory.	Dataset berhasil dimuat menggunakan Python.
2	Menelaah data	Memahami struktur dataset, jumlah baris, jumlah kolom, nama kolom, dan tipe data.	Dataset memiliki 5.000 baris dan 12 kolom.
3	Statistik deskriptif	Mengetahui gambaran umum nilai numerik dan kategorikal dalam dataset.	Dataset memiliki kolom numerik dan kategorikal yang dapat digunakan untuk analisis.
4	Pemeriksaan missing value	Mengetahui kolom yang memiliki nilai kosong.	Kolom writers memiliki 25 missing value.
5	Pembersihan missing value	Mengisi nilai kosong agar data dapat dianalisis secara lengkap.	Missing value pada kolom writers diisi dengan nilai unnamed.
6	Pemeriksaan duplikasi	Mengetahui apakah dataset memiliki baris duplikat.	Dataset tidak memiliki data duplikat.
7	Validasi outlier	Mengetahui nilai ekstrem pada kolom numerik.	Kolom averageRating memiliki 9 outlier dan kolom runtimeMinutes memiliki 150 outlier.
8	Keputusan penanganan outlier	Menentukan apakah outlier perlu dihapus atau dipertahankan.	Outlier tidak dihapus karena masih valid dalam konteks film IMDb.

1. Menelaah Data

Tahap menelaah data dilakukan untuk memahami struktur awal dataset. Penulis memuat dataset Top 5000 IMDb ke dalam Google Colaboratory menggunakan fungsi `pd.read_csv()`. Penulis menggunakan library `pandas`, `numpy`,

seaborn, dan matplotlib untuk mendukung proses pengolahan dan visualisasi data.

```
1 %%time
2 #import library utama
3 import numpy as np
4 import pandas as pd
5 import seaborn as sns
6 from matplotlib import pyplot as plt
7 import os
8
9 # Setting visualisasi
10 sns.set()
11 %matplotlib inline
12
13 #Menampilkan semua kolom
14 pd.set_option('display.max_columns', None)
```

```
CPU times: user 1.55 s, sys: 171 ms, total: 1.72 s
Wall time: 2.38 s
```

Gambar 3.2. Proses Import Library dan Load Dataset

Gambar 3.2 menunjukkan proses import library dan proses load dataset. Output tersebut menunjukkan bahwa dataset berhasil dimuat ke dalam dataframe bernama movie. Fungsi `movie.head()` menampilkan lima baris pertama dari dataset. Output tersebut digunakan untuk memastikan bahwa data sudah terbaca dengan benar di Google Colaboratory.

Setelah dataset berhasil dimuat, penulis memeriksa informasi dasar dataset. Pemeriksaan dilakukan dengan menggunakan `movie.shape`, `movie.columns`, `movie.dtypes`, dan `movie.info()`. Pemeriksaan ini dilakukan untuk mengetahui jumlah baris, jumlah kolom, nama kolom, tipe data, serta jumlah nilai non-null pada setiap kolom.

	tconst	primaryTitle	startYear	rank	averageRating	numVotes	runtimeMinutes	directors	writers	genres	IMDbLink	Title_IMDb_Link
0	tt0111161	The Shawshank Redemption	1994	1	9.3	3193141	142	Frank Darabont	Frank Darabont, Stephen King	Drama	https://www.imdb.com/title/tt0111161/...	https://www.imdb.com/title/tt0111161/...
1	tt0068646	The Godfather	1972	2	9.2	2228974	175	Francis Ford Coppola	Mario Puzo, Francis Ford Coppola	Crime, Drama	https://www.imdb.com/title/tt0068646/...	https://www.imdb.com/title/tt0068646/...
2	tt0468569	The Dark Knight	2008	3	9.1	3173646	152	Christopher Nolan	David S. Goyer, Jonathan Nolan, Christopher No...	Crime, Thriller	https://www.imdb.com/title/tt0468569/...	https://www.imdb.com/title/tt0468569/...
3	tt0167260	The Lord of the Rings: The Return of the King	2003	4	9.0	2166974	201	Peter Jackson	Philippa Boyens, Fran Walsh, Peter Jackson, J...	Adventure, Drama, Fantasy	https://www.imdb.com/title/tt0167260/...	https://www.imdb.com/title/tt0167260/...
4	tt0108052	Schindler's List	1993	5	9.0	1586572	195	Steven Spielberg	Thomas Keneally, Steven Zaillian	Biography, Drama, History	https://www.imdb.com/title/tt0108052/...	https://www.imdb.com/title/tt0108052/...

Gambar 3.3. Output Informasi Dasar Dataset

Gambar 3.3 menunjukkan bahwa dataset Top 5000 IMDb memiliki 5.000 baris dan 12 kolom. Dataset tersebut memiliki kolom tconst, primaryTitle, startYear, rank, averageRating, numVotes, runtimeMinutes, directors, writers, genres, IMDbLink, dan Title_IMDb_Link. Output tipe data menunjukkan bahwa dataset memiliki 1 kolom bertipe float64, 4 kolom bertipe int64, dan 7 kolom bertipe object.

Penulis juga melakukan pemeriksaan statistik deskriptif dan jumlah nilai unik pada setiap kolom. Pemeriksaan ini dilakukan dengan menggunakan `movie.describe(include="all")` dan `movie.nunique()`. Pemeriksaan ini membantu penulis memahami karakteristik umum dataset sebelum data digunakan untuk analisis lebih lanjut.

	tconst	primaryTitle	startYear	rank	averageRating	numVotes	runtimeMinutes	directors	writers	genres	IMDbLink	Title_IMDb_Link
count	5000	5000	5000.000000	5000.000000	5000.000000	5.000000e+03	5000.000000	5000	4975	5000	5000	
unique	5000	4901	NaN	NaN	NaN	NaN	NaN	2340	4401	367	5000	
top	tt0396652	Dracula	NaN	NaN	NaN	NaN	NaN	Woody Allen	Woody Allen	Comedy, Drama, Romance	https://www.imdb.com/title/tt0396652/...	https://www.imdb.com/title/tt0396652/...
freq	1	3	NaN	NaN	NaN	NaN	NaN	40	33	230	1	
mean	NaN	NaN	2002.219800	2500.500000	7.177240	1.673200e+05	115.140800	NaN	NaN	NaN	NaN	
std	NaN	NaN	18.689466	1443.520003	0.575149	2.532454e+05	23.601381	NaN	NaN	NaN	NaN	
min	NaN	NaN	1920.000000	1.000000	6.100000	2.502000e+04	25.000000	NaN	NaN	NaN	NaN	
25%	NaN	NaN	1994.000000	1250.750000	6.700000	3.996675e+04	99.000000	NaN	NaN	NaN	NaN	
50%	NaN	NaN	2007.000000	2500.500000	7.100000	7.276850e+04	111.000000	NaN	NaN	NaN	NaN	
75%	NaN	NaN	2016.000000	3750.250000	7.600000	1.812968e+05	127.000000	NaN	NaN	NaN	NaN	
max	NaN	NaN	2026.000000	5000.000000	9.300000	3.193141e+06	374.000000	NaN	NaN	NaN	NaN	

tconst	5000
primaryTitle	4901
startYear	106
rank	5000
averageRating	33
numVotes	4915
runtimeMinutes	164
directors	2340
writers	4401
genres	367
IMDbLink	5000
Title_IMDb_Link	5000

dtype: int64

Gambar 3.4. Output Statistik Deskriptif dan Jumlah Nilai Unik

Gambar 3.4 menunjukkan ringkasan statistik dataset. Output tersebut menunjukkan bahwa rata-rata averageRating adalah sekitar 7,17. Nilai minimum averageRating adalah 6,1 dan nilai maksimum averageRating adalah 9,3. Output tersebut juga menunjukkan bahwa nilai startYear berada pada rentang tahun 1920 sampai 2026. Informasi ini menunjukkan bahwa dataset memuat film dari periode lama hingga periode terbaru.

2. Memeriksa dan Membersihkan Missing Value

Tahap berikutnya adalah pemeriksaan missing value. Penulis menggunakan fungsi `movie.isnull().sum()` untuk mengetahui jumlah nilai kosong pada setiap kolom. Pemeriksaan ini penting karena missing value dapat memengaruhi hasil analisis apabila tidak ditangani dengan tepat.

	0
tconst	0
primaryTitle	0
startYear	0
rank	0
averageRating	0
numVotes	0
runtimeMinutes	0
directors	0
writers	25
genres	0
IMDbLink	0
Title_IMDb_Link	0
dtype:	int64

Gambar 3.5. Output Pemeriksaan Missing Value Awal

Gambar 3.5 menunjukkan bahwa sebagian besar kolom tidak memiliki missing value. Namun, kolom writers memiliki 25 missing value. Jumlah tersebut setara dengan 0,5% dari total 5.000 data. Kolom writers perlu dibersihkan karena kolom tersebut dapat digunakan untuk analisis karakteristik film dan sistem rekomendasi berbasis film.

Penulis membersihkan missing value pada kolom writers dengan mengganti nilai kosong menjadi unamed. Penulis menggunakan fungsi replace() untuk mengubah nilai kosong atau spasi menjadi NaN. Penulis kemudian menggunakan fungsi fillna() untuk mengisi nilai kosong dengan teks unamed.

```
...
dtype: int64
tconst      0
primaryTitle 0
startYear   0
rank         0
averageRating 0
numVotes     0
runtimeMinutes 0
directors    0
writers      0
genres       0
IMDbLink     0
Title_IMDb_Link 0
```

Gambar 3.6. Output Pembersihan Missing Value pada Kolom Writers

Gambar 3.6 menunjukkan bahwa missing value pada kolom writers berhasil dibersihkan. Output pengecekan ulang menunjukkan bahwa semua kolom sudah memiliki jumlah missing value sebesar 0. Dengan demikian, dataset sudah lebih lengkap dan dapat digunakan untuk proses analisis selanjutnya.

3. Memeriksa Duplikasi Data

Penulis melakukan pemeriksaan duplikasi data untuk memastikan bahwa dataset tidak memiliki baris yang tercatat lebih dari satu kali. Pemeriksaan duplikasi dilakukan dengan menggunakan fungsi movie.duplicated().sum().


```
Jumlah data duplikat: 0
tconst primaryTitle startYear rank averageRating numVotes runtimeMinutes directors writers genres IMDbLink Title_IMDb_Link
```

Gambar 3.7. Output Validasi Duplikasi Data

Gambar 3.7 menunjukkan bahwa jumlah data duplikat adalah 0. Hasil tersebut menunjukkan bahwa dataset tidak memiliki baris duplikat. Oleh karena itu, penulis tidak melakukan penghapusan data duplikat pada tahap ini.


4. Memvalidasi Data Numerik dan Outlier

Penulis melakukan validasi data numerik untuk memeriksa nilai ekstrem pada kolom `averageRating` dan `runtimeMinutes`. Penulis menggunakan boxplot untuk melihat sebaran data dan kemungkinan outlier. Kolom `averageRating` digunakan karena kolom tersebut menunjukkan nilai rating film. Kolom `runtimeMinutes` digunakan karena kolom tersebut menunjukkan durasi film dalam satuan menit.



Gambar 3.8. Boxplot Average Rating

Gambar 3.8 menunjukkan sebaran nilai `averageRating`. Boxplot tersebut memperlihatkan beberapa titik outlier pada sisi atas. Titik tersebut menunjukkan film dengan rating sangat tinggi. Nilai tersebut tidak langsung dianggap sebagai kesalahan data karena film dengan rating sangat tinggi dapat terjadi dalam konteks IMDb.



Gambar 3.9. Boxplot Runtime Minutes

Gambar 3.9 menunjukkan sebaran nilai runtimeMinutes. Boxplot tersebut memperlihatkan adanya beberapa outlier pada sisi bawah dan sisi atas. Outlier sisi bawah menunjukkan film dengan durasi sangat pendek. Outlier sisi atas menunjukkan film dengan durasi sangat panjang. Nilai tersebut masih dapat terjadi dalam konteks film, misalnya film pendek, TV special, animasi pendek, atau film epik berdurasi panjang.

Penulis juga menghitung outlier menggunakan metode IQR atau Interquartile Range. Metode ini menggunakan nilai Q1, Q3, IQR, lower bound, dan upper bound untuk menentukan batas nilai outlier.

Tabel 3.4. Ringkasan Hasil Validasi Outlier

No	Kolom	Q1	Q3	IQR	Lower Bound	Upper Bound	Outlier Sisi Q1	Outlier Sisi Q3	Total Outlier
1	averageRating	6,7	7,6	0,9	5,35	8,95	0	9	9
2	runtimeMinutes	99,0	127,0	28,0	57,00	169,00	8	142	150

Tabel 3.4 menunjukkan bahwa kolom averageRating memiliki 9 outlier. Outlier pada kolom tersebut berada pada sisi Q3 atau upper outlier. Tabel tersebut juga menunjukkan bahwa kolom runtimeMinutes memiliki 150 outlier. Outlier pada kolom runtimeMinutes terdiri dari 8 outlier pada sisi Q1 dan 142 outlier pada sisi Q3.

	primaryTitle	startYear	averageRating	runtimeMinutes	kolom_outlier	posisi_outlier
0	The Shawshank Redemption	1994	9.3	142	averageRating	Sisi Q3 / Upper Outlier
1	The Godfather	1972	9.2	175	averageRating	Sisi Q3 / Upper Outlier
2	The Dark Knight	2008	9.1	152	averageRating	Sisi Q3 / Upper Outlier
3	The Lord of the Rings: The Return of the King	2003	9.0	201	averageRating	Sisi Q3 / Upper Outlier
4	Schindler's List	1993	9.0	195	averageRating	Sisi Q3 / Upper Outlier
5	The Godfather Part II	1974	9.0	202	averageRating	Sisi Q3 / Upper Outlier
6	12 Angry Men	1957	9.0	96	averageRating	Sisi Q3 / Upper Outlier
71	The Chaos Class	1975	9.1	85	averageRating	Sisi Q3 / Upper Outlier
147	Attack on Titan: The Last Attack	2024	9.0	145	averageRating	Sisi Q3 / Upper Outlier
308	How the Grinch Stole Christmas!	1966	8.3	26	runtimeMinutes	Sisi Q1 / Lower Outlier
417	Sherlock Jr.	1924	8.1	45	runtimeMinutes	Sisi Q1 / Lower Outlier
424	A Charlie Brown Christmas	1965	8.3	25	runtimeMinutes	Sisi Q1 / Lower Outlier
777	Rudolph the Red-Nosed Reindeer	1964	8.0	47	runtimeMinutes	Sisi Q1 / Lower Outlier
779	Endless Corridor	2014	8.0	52	runtimeMinutes	Sisi Q1 / Lower Outlier
1380	To the Forest of Firefly Lights	2011	7.8	45	runtimeMinutes	Sisi Q1 / Lower Outlier
1958	The Garden of Words	2013	7.4	46	runtimeMinutes	Sisi Q1 / Lower Outlier
2641	Werewolf by Night	2022	7.1	52	runtimeMinutes	Sisi Q1 / Lower Outlier
1	The Godfather	1972	9.2	175	runtimeMinutes	Sisi Q3 / Upper Outlier
3	The Lord of the Rings: The Return of the King	2003	9.0	201	runtimeMinutes	Sisi Q3 / Upper Outlier
4	Schindler's List	1993	9.0	195	runtimeMinutes	Sisi Q3 / Upper Outlier

Gambar 3.10. Output Detail Record yang Termasuk Outlier

Gambar 3.10 menunjukkan contoh film yang termasuk outlier. Film seperti *The Shawshank Redemption*, *The Godfather*, dan *The Dark Knight* termasuk outlier pada kolom *averageRating* karena memiliki rating sangat tinggi. Namun, film tersebut bukan kesalahan data karena film tersebut memang dikenal sebagai film dengan rating tinggi. Beberapa film juga termasuk outlier pada kolom *runtimeMinutes* karena memiliki durasi sangat pendek atau sangat panjang.

Berdasarkan hasil validasi tersebut, penulis tidak menghapus outlier dari dataset utama. Penulis mempertahankan outlier karena nilai tersebut masih valid dalam konteks film IMDb. Keputusan ini dilakukan agar data penting tidak hilang dan hasil analisis tetap mencerminkan karakteristik asli dataset.

5. Hasil Akhir Proses Praproses

Setelah proses praproses dilakukan, dataset Top 5000 IMDb menjadi lebih siap untuk digunakan dalam analisis. Dataset sudah melalui tahap telaah data, pemeriksaan informasi dasar, pemeriksaan missing value, pembersihan missing value pada kolom *writers*, pemeriksaan duplikasi, validasi tipe data, dan validasi outlier. Dataset juga tetap mempertahankan outlier karena nilai ekstrem tersebut masih memiliki makna dalam konteks film.

Proses praproses ini menghasilkan dataset yang layak digunakan untuk tahap analisis berikutnya. Dataset tersebut kemudian digunakan untuk menentukan objek data, membuat visualisasi di Google Looker Studio, serta menghasilkan insight dan rekomendasi bisnis.

4. ANALISIS DATA

4.1 Eksplorasi Variabel Utama

Eksplorasi variabel utama dilakukan untuk menentukan objek data yang akan digunakan dalam analisis. Penulis melakukan tahap ini setelah dataset melewati proses telaah data, validasi data, dan pembersihan data. Tahap eksplorasi variabel utama dilakukan menggunakan Google Colaboratory.

Dataset Top 5000 IMDb memiliki beberapa kolom yang dapat digunakan untuk analisis. Namun, tidak semua kolom digunakan sebagai objek analisis utama. Penulis memilih kolom yang memiliki hubungan langsung dengan kebutuhan analisis, yaitu identitas film, tahun rilis, rating, jumlah votes, durasi, sutradara, penulis, dan genre. Kolom IMDbLink dan Title_IMDb_Link tidak digunakan sebagai objek analisis utama karena kedua kolom tersebut berfungsi sebagai tautan referensi, bukan sebagai fitur analitik utama.

Tabel 4.1. Variabel Utama yang Digunakan dalam Analisis

No	Variabel	Nama Kolom	Jenis Data	Fungsi dalam Analisis
1	Kode film	tconst	Kategorikal	Kolom ini digunakan sebagai identitas unik setiap film.
2	Judul film	primaryTitle	Kategorikal	Kolom ini digunakan untuk menampilkan nama film dalam analisis.
3	Tahun rilis	startYear	Numerik	Kolom ini digunakan untuk menganalisis tren jumlah film berdasarkan tahun rilis.
4	Peringkat film	rank	Numerik	Kolom ini menunjukkan urutan film dalam dataset Top 5000 IMDb.
5	Rating IMDb	averageRating	Numerik	Kolom ini digunakan untuk menganalisis kualitas penilaian film.
6	Jumlah votes	numVotes	Numerik	Kolom ini digunakan untuk menganalisis tingkat popularitas film.

7	Durasi film	runtimeMinutes	Numerik	Kolom ini digunakan untuk mengetahui durasi film dalam satuan menit.
8	Sutradara	directors	Kategorikal	Kolom ini digunakan untuk mengetahui sutradara film.
9	Penulis	writers	Kategorikal	Kolom ini digunakan untuk mengetahui penulis film.
10	Genre	genres	Kategorikal	Kolom ini digunakan untuk menganalisis kategori genre film.

Berdasarkan variabel tersebut, penulis menentukan objek data yang akan digunakan untuk visualisasi dan analisis lanjutan. Objek utama dalam laporan ini adalah genre film, tahun rilis, rating IMDb, jumlah votes, dan kategori rating. Objek tersebut dipilih karena dapat menjawab kebutuhan bisnis yang telah dijelaskan pada bab sebelumnya.

Tabel 4.2. Kesesuaian Objek Data dengan Pertanyaan Analisis

No	Pertanyaan Analisis	Objek Data	Variabel yang Digunakan
1	Genre film apa yang memiliki jumlah kemunculan terbanyak?	Genre film	genres, attribute_type, attribute_name
2	Bagaimana tren jumlah film berdasarkan tahun rilis?	Tahun rilis film	startYear, tconst
3	Bagaimana hubungan antara rating IMDb dan jumlah votes?	Rating dan popularitas film	averageRating, numVotes, primaryTitle
4	Bagaimana komposisi film berdasarkan kategori rating?	Kategori rating film	averageRating, tconst

Penulis melakukan transformasi data pada kolom genres, directors, dan writers. Transformasi ini dilakukan karena beberapa kolom tersebut memiliki lebih dari satu nilai dalam satu baris. Misalnya, satu film dapat memiliki lebih dari satu genre, lebih dari satu sutradara, atau lebih dari satu penulis. Jika nilai tersebut tidak dipisahkan, sistem visualisasi dapat membaca gabungan nilai

sebagai satu kategori. Oleh karena itu, penulis memisahkan nilai pada kolom tersebut agar setiap genre, sutradara, dan penulis dapat dianalisis satu per satu.

Penulis menyusun dataset objek analisis dalam format long data. Format ini menambahkan dua kolom baru, yaitu `attribute_type` dan `attribute_name`. Kolom `attribute_type` menunjukkan jenis atribut, seperti genre, director, atau writer. Kolom `attribute_name` menunjukkan nama atribut yang sudah dipisahkan. Format ini memudahkan proses visualisasi data karena setiap atribut dapat dihitung berdasarkan kategorinya masing-masing.

```
1 # Membuat dataset untuk Looker Studio
2 movie_looker = movie.copy()
3
4 # Kolom dasar yang tetap dipertahankan
5 base_columns = [
6     "tconst",
7     "primaryTitle",
8     "startYear",
9     "rank",
10    "averageRating",
11    "numVotes",
12    "runtimeMinutes",
13    "directors",
14    "writers",
15    "genres"
16 ]
17
18 # Membuat data genre
19 movie_genre = movie_looker[base_columns].copy()
20 movie_genre["attribute_type"] = "genre"
21 movie_genre["attribute_name"] = movie_genre["genres"].str.split(",")
22
23 # Membuat data director
24 movie_director = movie_looker[base_columns].copy()
25 movie_director["attribute_type"] = "director"
26 movie_director["attribute_name"] = movie_director["directors"].str.split(",")
27
28 # Membuat data writer
29 movie_writer = movie_looker[base_columns].copy()
30 movie_writer["attribute_type"] = "writer"
31 movie_writer["attribute_name"] = movie_writer["writers"].str.split(",")
32
```

Gambar 4.1. Proses Pembentukan Dataset Objek Analisis

Gambar 4.1 menunjukkan proses pembentukan dataset objek analisis. Penulis membuat salinan dataset utama, menentukan kolom dasar, membuat data untuk genre, sutradara, dan penulis, lalu menggabungkan ketiga data tersebut. Penulis menggunakan fungsi `str.split()` untuk memisahkan nilai yang masih tergabung dalam satu kolom. Penulis juga menggunakan fungsi `explode()` untuk mengubah nilai yang berbentuk daftar menjadi baris terpisah.

Setelah proses transformasi dilakukan, penulis memilih kolom yang digunakan sebagai objek analisis. Kolom yang dipilih adalah `tconst`, `primaryTitle`,

startYear, rank, averageRating, numVotes, runtimeMinutes, directors, writers, genres, attribute_type, dan attribute_name. Kolom tersebut kemudian disimpan ke dalam dataframe baru bernama movie_object.

tconst	primaryTitle	startYear	rank	averageRating	numVotes	runtimeMinutes	directors	writers	genres	attribute_type	attribute_name
0 tt0111161	The Shawshank Redemption	1994	1	9.3	3193141	142	Frank Darabont	Frank Darabont, Stephen King	Drama	genre	Drama
1 tt0068646	The Godfather	1972	2	9.2	2228974	175	Francis Ford Coppola	Mario Puzo, Francis Ford Coppola	Crime, Drama	genre	Crime
1 tt0068646	The Godfather	1972	2	9.2	2228974	175	Francis Ford Coppola	Mario Puzo, Francis Ford Coppola	Crime, Drama	genre	Drama
2 tt0468569	The Dark Knight	2008	3	9.1	3173646	152	Christopher Nolan	David S. Goyer, Jonathan Nolan, Christopher No...	Crime, Thriller	genre	Crime
2 tt0468569	The Dark Knight	2008	3	9.1	3173646	152	Christopher Nolan	David S. Goyer, Jonathan Nolan, Christopher No...	Crime, Thriller	genre	Thriller
3 tt0167260	The Lord of the Rings: The Return of the King	2003	4	9.0	2166974	201	Peter Jackson	Philippa Boyens, Fran Walsh, Peter Jackson, J....	Adventure, Drama, Fantasy	genre	Adventure
3 tt0167260	The Lord of the Rings: The Return of the King	2003	4	9.0	2166974	201	Peter Jackson	Philippa Boyens, Fran Walsh, Peter Jackson, J....	Adventure, Drama, Fantasy	genre	Drama
3 tt0167260	The Lord of the Rings: The Return of the King	2003	4	9.0	2166974	201	Peter Jackson	Philippa Boyens, Fran Walsh, Peter Jackson, J....	Adventure, Drama, Fantasy	genre	Fantasy
4 tt0108052	Schindler's List	1993	5	9.0	1586572	195	Steven Spielberg	Thomas Keneally, Steven Zaillian	Biography, Drama, History	genre	Biography
4 tt0108052	Schindler's List	1993	5	9.0	1586572	195	Steven Spielberg	Thomas Keneally, Steven Zaillian	Biography, Drama, History	genre	Drama

Gambar 4.2. Output Dataset Objek Analisis movie_object

Gambar 4.2 menunjukkan hasil pembentukan dataset objek analisis. Output tersebut menunjukkan bahwa data film sudah memiliki kolom attribute_type dan attribute_name. Kolom tersebut membantu proses analisis karena genre, sutradara, dan penulis sudah dapat dihitung secara terpisah. Setelah transformasi dilakukan, dataset objek analisis memiliki 12 kolom dan 31.335 baris. Jumlah baris meningkat karena satu film dapat memiliki lebih dari satu genre, sutradara, atau penulis.

Penulis juga membentuk kelompok variabel Specs dan Score. Variabel Specs berisi fitur numerik yang dapat digunakan untuk analisis, yaitu startYear, rank, numVotes, dan runtimeMinutes. Variabel Score berisi nilai yang ingin dianalisis, yaitu averageRating.

Tabel 4.3. Pembentukan Specs dan Score

No	Kelompok	Kolom	Keterangan
1	Specs	startYear	Kolom ini menunjukkan tahun rilis film.
2	Specs	rank	Kolom ini menunjukkan peringkat film dalam dataset.
3	Specs	numVotes	Kolom ini menunjukkan jumlah votes atau penilaian pengguna.
4	Specs	runtimeMinutes	Kolom ini menunjukkan durasi film dalam satuan menit.


5	Score	averageRating	Kolom ini menunjukkan nilai rata-rata rating IMDb.
---	-------	---------------	--

	startYear	rank	numVotes	runtimeMinutes
0	1994	1	3193141	142
1	1972	2	2228974	175
2	2008	3	3173646	152
3	2003	4	2166974	201
4	1993	5	1586572	195

Gambar 4.3. Output Pembentukan Specs dan Score

Gambar 4.3 menunjukkan hasil pembentukan Specs dan Score. Output tersebut menunjukkan bahwa fitur numerik dipisahkan dari nilai target yang ingin dianalisis. Pemisahan ini membantu penulis memahami hubungan antara fitur numerik dengan rating film.

Penulis kemudian melakukan analisis korelasi terhadap fitur numerik. Analisis korelasi dilakukan untuk mengetahui hubungan antarvariabel numerik dalam dataset. Variabel yang dianalisis meliputi startYear, rank, averageRating, numVotes, dan runtimeMinutes.



Gambar 4.4. Heatmap Korelasi Fitur Numerik IMDb

Gambar 4.4 menunjukkan hasil korelasi antarfitur numerik. Hasil korelasi menunjukkan bahwa `averageRating` memiliki hubungan positif dengan `numVotes` sebesar 0,396996. Nilai tersebut menunjukkan bahwa film dengan rating lebih tinggi cenderung memiliki jumlah votes yang lebih besar, meskipun hubungan tersebut tidak terlalu kuat. Hasil korelasi juga menunjukkan bahwa `rank` memiliki hubungan negatif yang sangat kuat dengan `averageRating`, yaitu sebesar -0,973065. Hal ini terjadi karena peringkat film dalam dataset disusun berdasarkan kualitas atau popularitas tertentu, sehingga film dengan rating tinggi cenderung memiliki angka peringkat yang lebih kecil.

Berdasarkan hasil eksplorasi variabel utama, penulis menetapkan empat fokus analisis. Fokus pertama adalah jumlah kemunculan genre film. Fokus kedua adalah tren jumlah film berdasarkan tahun rilis. Fokus ketiga adalah hubungan antara rating IMDb dan jumlah votes. Fokus keempat adalah komposisi film berdasarkan kategori rating. Keempat fokus tersebut kemudian divisualisasikan menggunakan Google Looker Studio pada bagian berikutnya.

4.2 Visualisasi Data

Visualisasi data dilakukan untuk menampilkan hasil analisis dalam bentuk grafik yang lebih mudah dipahami. Penulis menggunakan dua alat pada tahap ini. Google Colaboratory digunakan untuk memeriksa duplikasi data dan menampilkan korelasi antarfitur numerik. Google Looker Studio digunakan untuk membuat dashboard visualisasi data berdasarkan dataset objek analisis yang sudah disiapkan.

Visualisasi data dalam laporan ini berfokus pada empat pertanyaan utama analisis. Pertanyaan pertama membahas genre film yang paling banyak muncul. Pertanyaan kedua membahas tren jumlah film berdasarkan tahun rilis. Pertanyaan ketiga membahas hubungan antara rating IMDb dan jumlah votes. Pertanyaan keempat membahas komposisi film berdasarkan kategori rating.

Tabel 4.4. Jenis Visualisasi dan Tujuan Analisis

No	Jenis Visualisasi	Variabel yang Digunakan	Tujuan Visualisasi
1	Validasi duplikasi data	Seluruh kolom dataset	Memastikan bahwa dataset tidak memiliki baris duplikat.

2	Heatmap korelasi	startYear, rank, averageRating, numVotes, runtimeMinutes	Mengetahui hubungan antarfitur numerik dalam dataset.
3	Horizontal bar chart	attribute_name, attribute_type, tconst	Menampilkan genre film dengan jumlah kemunculan terbanyak.
4	Line chart	startYear, tconst	Menampilkan tren jumlah film berdasarkan tahun rilis.
5	Scatter chart	averageRating, numVotes, primaryTitle	Menampilkan hubungan antara rating IMDb dan jumlah votes.
6	Pie chart	averageRating, tconst	Menampilkan komposisi film berdasarkan kategori rating.

1. Validasi Duplikasi Data

Penulis melakukan validasi duplikasi data sebelum membuat visualisasi utama. Validasi ini dilakukan untuk memastikan bahwa data yang dianalisis tidak memiliki baris yang tercatat lebih dari satu kali. Penulis menggunakan fungsi `movie_object.duplicated().sum()` pada Google Colaboratory.


```
Jumlah data duplikat: 0
tconst primaryTitle startYear rank averageRating numVotes runtimeMinutes directors writers genres attribute_type attribute_name
```

Gambar 4.5. Output Validasi Duplikasi Data

Gambar 4.5 menunjukkan bahwa jumlah data duplikat adalah 0. Hasil tersebut menunjukkan bahwa dataset tidak memiliki baris duplikat. Oleh karena itu, penulis tidak melakukan penghapusan data duplikat pada tahap visualisasi data.

2. Korelasi Antarfitur Numerik

Penulis menampilkan korelasi antarfitur numerik untuk mengetahui hubungan antarvariabel dalam dataset. Fitur numerik yang digunakan dalam korelasi adalah `startYear`, `rank`, `averageRating`, `numVotes`, dan `runtimeMinutes`. Penulis menggunakan heatmap agar hubungan antarvariabel dapat dibaca dengan lebih mudah.




Gambar 4.6. Heatmap Korelasi Fitur Numerik IMDb

Gambar 4.6 menunjukkan hubungan antarfitur numerik dalam dataset Top 5000 IMDb. Hasil korelasi menunjukkan bahwa averageRating memiliki hubungan positif dengan numVotes. Nilai korelasi positif tersebut menunjukkan bahwa film dengan rating lebih tinggi cenderung memiliki jumlah votes yang lebih besar. Namun, hubungan tersebut tidak bersifat mutlak karena jumlah votes juga dapat dipengaruhi oleh popularitas, usia film, promosi, dan minat penonton.

Hasil korelasi juga menunjukkan bahwa rank memiliki hubungan negatif yang kuat dengan averageRating. Hal ini terjadi karena film dengan rating yang lebih tinggi cenderung berada pada peringkat yang lebih kecil dalam daftar Top 5000 IMDb. Dengan demikian, korelasi ini membantu penulis memahami hubungan antara peringkat, rating, votes, tahun rilis, dan durasi film.

3. Genre Film dengan Jumlah Kemunculan Terbanyak

Penulis membuat horizontal bar chart untuk menampilkan genre film dengan jumlah kemunculan terbanyak. Visualisasi ini menggunakan dimensi attribute_name dan metrik jumlah film. Filter attribute_type = genre digunakan agar chart hanya menampilkan data genre.




Gambar 4.7. Genre Film dengan Jumlah Kemunculan Terbanyak

Gambar 4.7 menunjukkan bahwa genre Drama memiliki jumlah kemunculan tertinggi, yaitu 3.207 kemunculan. Genre Comedy berada pada posisi kedua dengan 1.617 kemunculan. Genre Crime berada pada posisi ketiga dengan 1.112 kemunculan. Genre Action berada pada posisi keempat dengan 1.087 kemunculan. Genre Adventure berada pada posisi kelima dengan 908 kemunculan.

Hasil visualisasi ini menunjukkan bahwa dataset Top 5000 IMDb didominasi oleh genre Drama. Temuan ini menunjukkan bahwa genre Drama memiliki cakupan film yang luas dan sering muncul bersama genre lain. Informasi ini dapat digunakan oleh platform film untuk menyusun strategi katalog dan promosi film berdasarkan genre yang paling dominan.

4. Tren Jumlah Film Berdasarkan Tahun Rilis

Penulis membuat line chart untuk menampilkan tren jumlah film berdasarkan tahun rilis. Visualisasi ini menggunakan startYear sebagai sumbu X dan jumlah film unik sebagai sumbu Y. Metrik jumlah film dihitung menggunakan Count Distinct tconst agar satu film hanya dihitung satu kali.




Gambar 4.8. Tren Jumlah Film Berdasarkan Tahun Rilis

Gambar 4.8 menunjukkan bahwa jumlah film dalam dataset cenderung meningkat dari periode awal 1920-an hingga periode modern. Jumlah film mulai meningkat lebih jelas pada periode 1990-an dan terus mengalami kenaikan pada periode 2000-an sampai 2010-an. Hasil ini menunjukkan bahwa dataset Top 5000 IMDb lebih banyak memuat film dari periode modern dibandingkan film dari periode lama.

Penurunan jumlah film pada tahun terbaru perlu ditafsirkan secara hati-hati. Penurunan tersebut tidak selalu menunjukkan bahwa jumlah produksi film menurun. Penurunan tersebut dapat terjadi karena data tahun terbaru belum sepenuhnya lengkap atau belum semua film baru masuk ke dalam daftar Top 5000 IMDb.

5. Hubungan Rating IMDb dan Jumlah Votes

Penulis membuat scatter chart untuk menampilkan hubungan antara rating IMDb dan jumlah votes. Visualisasi ini menggunakan averageRating sebagai sumbu X dan numVotes sebagai sumbu Y. Setiap titik dalam scatter chart merepresentasikan film dalam dataset.



Gambar 4.9. Hubungan Rating IMDb dan Jumlah Votes


Gambar 4.9 menunjukkan bahwa film dengan rating IMDb tinggi cenderung memiliki jumlah votes yang besar. Titik-titik pada grafik menunjukkan bahwa beberapa film dengan rating di atas 8,5 memiliki jumlah votes yang sangat tinggi. Namun, tidak semua film dengan rating tinggi memiliki jumlah votes yang besar. Hal ini menunjukkan bahwa rating film dan popularitas film saling berkaitan, tetapi keduanya tidak selalu bergerak secara sama.

Insight dari visualisasi ini adalah sistem rekomendasi film sebaiknya tidak hanya menggunakan rating. Sistem rekomendasi perlu mempertimbangkan jumlah votes agar rekomendasi tidak bias terhadap film yang memiliki rating tinggi tetapi jumlah penilaiannya sedikit. Kombinasi rating dan votes dapat menghasilkan rekomendasi yang lebih stabil dan lebih relevan bagi pengguna.

6. Komposisi Film Berdasarkan Kategori Rating

Penulis membuat pie chart untuk menampilkan komposisi film berdasarkan kategori rating. Penulis membagi rating menjadi tiga kategori, yaitu Rating Tinggi, Rating Sedang, dan Rating Rendah. Rating Tinggi mencakup film dengan nilai 8,0 sampai 10. Rating Sedang mencakup film dengan nilai 7,0 sampai 7,9. Rating Rendah mencakup film dengan nilai di bawah 7,0.

KOMPOSISI FILM BERDASARKAN KATEGORI RATING




Gambar 4.10. Komposisi Film Berdasarkan Kategori Rating

Gambar 4.10 menunjukkan bahwa sebagian besar film berada pada kategori Rating Sedang. Kategori Rating Sedang memiliki proporsi sebesar 50%. Kategori Rating Rendah memiliki proporsi sebesar 38,9%. Kategori Rating Tinggi memiliki proporsi sebesar 11,2%.

Hasil visualisasi ini menunjukkan bahwa film dengan rating tinggi memiliki jumlah yang lebih sedikit dibandingkan film dengan rating sedang dan rendah. Oleh karena itu, film dengan Rating Tinggi dapat diposisikan sebagai film unggulan. Film dengan Rating Sedang dapat digunakan sebagai basis katalog utama karena jumlahnya paling besar dalam dataset.

7. Dashboard Visualisasi Data

Penulis menggabungkan seluruh visualisasi utama ke dalam satu dashboard di Google Looker Studio. Dashboard tersebut memuat visualisasi genre film, tren tahun rilis, hubungan rating dan votes, serta komposisi kategori rating.



Gambar 4.11. Dashboard Analisis Film IMDb Berdasarkan Genre, Rating, Votes, dan Tahun Rilis

Gambar 4.11 menunjukkan tampilan dashboard akhir yang digunakan dalam laporan ini. Dashboard tersebut membantu pembaca memahami hasil analisis secara ringkas dan terstruktur. Dashboard ini juga memudahkan proses penyusunan insight dan rekomendasi bisnis karena setiap grafik menjawab pertanyaan analisis yang berbeda.

5. TEMUAN & INSIGHT

Berdasarkan hasil pengumpulan data, praproses data, eksplorasi variabel utama, dan visualisasi data, penulis memperoleh beberapa temuan utama dari dataset Top 5000 IMDb. Temuan ini diperoleh dari hasil analisis menggunakan Google Colaboratory dan Google Looker Studio. Dataset yang digunakan telah melalui proses pemeriksaan missing value, duplikasi, outlier, pemilihan objek data, dan visualisasi data. Oleh karena itu, temuan yang dihasilkan dapat digunakan untuk memahami karakteristik film dalam dataset IMDb.

1. Temuan Utama

Temuan pertama menunjukkan bahwa dataset Top 5000 IMDb didominasi oleh genre Drama. Hasil visualisasi bar chart menunjukkan bahwa genre Drama memiliki jumlah kemunculan tertinggi, yaitu 3.207 kemunculan. Genre Comedy berada pada posisi kedua dengan 1.617 kemunculan. Genre Crime berada pada posisi ketiga dengan 1.112 kemunculan. Genre Action berada pada posisi keempat dengan 1.087 kemunculan. Genre Adventure berada pada posisi kelima dengan 908 kemunculan. Temuan ini menunjukkan bahwa genre Drama menjadi genre yang paling banyak muncul dalam dataset Top 5000 IMDb.

Temuan kedua menunjukkan bahwa film dalam dataset lebih banyak berasal dari periode modern. Hasil visualisasi line chart menunjukkan bahwa jumlah film cenderung meningkat dari periode awal 1920-an menuju periode 2000-an dan 2010-an. Jumlah film pada periode lama masih relatif sedikit, sedangkan jumlah film pada periode modern terlihat lebih dominan. Temuan ini menunjukkan bahwa dataset Top 5000 IMDb lebih banyak memuat film yang dirilis pada era modern dibandingkan film yang dirilis pada periode awal industri film.

Temuan ketiga menunjukkan bahwa rating IMDb memiliki hubungan positif dengan jumlah votes. Hasil scatter chart menunjukkan bahwa film dengan rating IMDb yang tinggi cenderung memiliki jumlah votes yang besar. Namun, hubungan tersebut tidak selalu mutlak karena terdapat beberapa film dengan rating tinggi tetapi jumlah votes lebih rendah. Temuan ini menunjukkan bahwa kualitas penilaian film dan popularitas film saling berkaitan, tetapi sistem rekomendasi tidak cukup hanya menggunakan rating sebagai dasar utama.

Temuan keempat menunjukkan bahwa mayoritas film berada pada kategori Rating Sedang. Hasil pie chart menunjukkan bahwa film dengan Rating Sedang (7,0–7,9) memiliki proporsi sebesar 50%. Film dengan Rating Rendah (<7,0) memiliki proporsi sebesar 38,9%. Film dengan Rating Tinggi (8,0–10)

memiliki proporsi sebesar 11,2%. Temuan ini menunjukkan bahwa film dengan rating sangat tinggi memiliki jumlah yang lebih terbatas dibandingkan film dengan rating sedang dan rendah.

Temuan kelima menunjukkan bahwa data memiliki kualitas yang cukup baik untuk dianalisis. Hasil praproses menunjukkan bahwa dataset tidak memiliki data duplikat. Dataset hanya memiliki missing value pada kolom writers, kemudian nilai kosong tersebut sudah diisi dengan nilai unamed. Hasil validasi outlier menunjukkan bahwa terdapat outlier pada averageRating dan runtimeMinutes. Namun, outlier tersebut tidak dihapus karena masih memiliki makna yang valid dalam konteks film IMDb.

2. Ringkasan Insight

Tabel 5.1. Ringkasan Temuan dan Insight

No	Aspek Analisis	Temuan Utama	Insight
1	Genre film	Genre Drama memiliki jumlah kemunculan tertinggi, yaitu 3.207 kemunculan.	Genre Drama menjadi genre paling dominan dalam dataset dan dapat menjadi perhatian utama dalam analisis katalog film.
2	Genre populer lain	Genre Comedy, Crime, Action, dan Adventure berada setelah Drama.	Genre-genre tersebut memiliki jumlah kemunculan tinggi dan berpotensi menarik minat pengguna.
3	Tahun rilis	Jumlah film cenderung meningkat menuju periode modern, khususnya pada 2000-an dan 2010-an.	Dataset Top 5000 IMDb lebih banyak merepresentasikan film modern dibandingkan film lama.
4	Rating dan votes	Rating IMDb memiliki hubungan positif dengan jumlah votes.	Film dengan rating tinggi dan votes besar dapat dianggap sebagai film yang memiliki kualitas dan popularitas tinggi.
5	Kategori rating	Rating Sedang (7,0–7,9) memiliki proporsi terbesar, yaitu 50%.	Sebagian besar film dalam dataset berada pada kategori kualitas menengah hingga baik.

6	Rating tinggi	Rating Tinggi (8,0–10) hanya memiliki proporsi 11,2%.	Film dengan rating tinggi memiliki jumlah lebih terbatas dan dapat diposisikan sebagai film unggulan.
7	Kualitas data	Dataset tidak memiliki data duplikat dan missing value telah dibersihkan.	Dataset sudah layak digunakan untuk analisis visual dan penyusunan rekomendasi berbasis data.

Berdasarkan ringkasan insight tersebut, dataset Top 5000 IMDb menunjukkan bahwa genre Drama menjadi genre paling dominan, film modern lebih banyak muncul dalam dataset, rating IMDb memiliki hubungan positif dengan jumlah votes, dan sebagian besar film berada pada kategori Rating Sedang. Temuan ini menjadi dasar untuk menyusun peluang bisnis pada bab berikutnya.

6. PELUANG BISNIS

Berdasarkan temuan dan insight yang diperoleh, terdapat beberapa peluang bisnis yang dapat dimanfaatkan oleh rumah produksi, platform film, layanan streaming, atau penyedia katalog film. Peluang bisnis ini disusun berdasarkan hasil visualisasi genre, tren tahun rilis, hubungan rating dan votes, serta komposisi kategori rating.

Peluang bisnis pertama adalah peningkatan produksi dan akuisisi film pada genre yang paling dominan. Hasil analisis menunjukkan bahwa genre Drama memiliki jumlah kemunculan tertinggi dalam dataset Top 5000 IMDb. Rumah produksi dan platform film dapat memanfaatkan peluang ini dengan memperbanyak produksi, pembelian lisensi, atau akuisisi film bergenre Drama. Genre Drama juga dapat dikembangkan ke dalam beberapa variasi, seperti drama keluarga, drama romantis, drama kriminal, dan drama sejarah agar pilihan film menjadi lebih luas.

Peluang bisnis kedua adalah pengembangan film pada genre populer lain. Hasil analisis menunjukkan bahwa genre Comedy, Crime, Action, dan Adventure memiliki jumlah kemunculan tinggi setelah Drama. Perusahaan dapat memanfaatkan peluang ini dengan mengembangkan film baru atau memperoleh lisensi film dari genre-genre tersebut. Strategi ini dapat membantu perusahaan memperluas pilihan film dan menjangkau kelompok penonton yang berbeda.

Peluang bisnis ketiga adalah penguatan promosi berbasis genre. Platform film dapat membuat kampanye promosi berdasarkan genre yang memiliki jumlah kemunculan tinggi. Platform dapat membuat tema promosi seperti “Drama Pilihan”, “Action Terpopuler”, “Crime Movie Collection”, atau “Adventure Weekend”. Strategi ini dapat membantu pengguna menemukan film sesuai minatnya dan dapat meningkatkan keterlibatan pengguna terhadap katalog film.

Peluang bisnis keempat adalah pemilihan film unggulan berdasarkan kombinasi rating dan jumlah votes. Hasil analisis menunjukkan bahwa rating IMDb memiliki hubungan positif dengan jumlah votes. Perusahaan dapat memanfaatkan peluang ini dengan memilih film yang memiliki rating tinggi dan jumlah votes besar sebagai film utama. Film dengan dua indikator tersebut dapat dianggap memiliki kualitas penilaian dan tingkat popularitas yang lebih kuat.

Peluang bisnis kelima adalah penempatan film dengan Rating Tinggi sebagai film premium. Hasil visualisasi menunjukkan bahwa film dengan Rating Tinggi (8,0–10) memiliki proporsi yang lebih kecil dibandingkan kategori rating lainnya. Karena jumlahnya lebih terbatas, film dalam kategori ini dapat

diposisikan sebagai film unggulan, film premium, atau rekomendasi utama. Strategi ini dapat meningkatkan daya tarik platform karena pengguna dapat menemukan film berkualitas tinggi secara lebih mudah.

Peluang bisnis keenam adalah pengembangan film berdasarkan periode tahun rilis. Hasil visualisasi menunjukkan bahwa film modern lebih banyak muncul dalam dataset dibandingkan film lama. Perusahaan dapat memanfaatkan peluang ini dengan memperbanyak akuisisi dan promosi film modern. Namun, perusahaan juga dapat mempertahankan film klasik berkualitas untuk menjangkau segmen penonton yang menyukai film lama atau film populer lintas generasi.

Berdasarkan peluang bisnis tersebut, perusahaan dapat meningkatkan nilai bisnis dari data film melalui produksi film, akuisisi film, promosi genre, pengelolaan katalog, dan sistem rekomendasi. Peluang bisnis yang paling utama adalah memperbanyak produksi atau akuisisi film pada genre Drama, Comedy, Crime, Action, dan Adventure, serta memilih film unggulan berdasarkan kombinasi rating dan jumlah votes.

7. KESIMPULAN DAN REKOMENDASI

Berdasarkan hasil analisis dataset Top 5000 IMDb, penulis menyimpulkan bahwa data film dapat digunakan untuk mendukung pengambilan keputusan bisnis pada industri hiburan digital. Analisis ini menunjukkan bahwa genre Drama menjadi genre yang paling dominan dalam dataset. Genre Comedy, Crime, Action, dan Adventure juga memiliki jumlah kemunculan yang tinggi. Temuan tersebut menunjukkan bahwa genre-genre tersebut memiliki potensi bisnis yang besar untuk dikembangkan dalam strategi produksi, akuisisi, promosi, dan pengelolaan katalog film.

Hasil analisis juga menunjukkan bahwa film dalam dataset lebih banyak berasal dari periode modern, khususnya pada tahun 2000-an dan 2010-an. Kondisi tersebut menunjukkan bahwa film modern memiliki representasi yang kuat dalam dataset Top 5000 IMDb. Namun, film klasik tetap memiliki nilai bisnis karena beberapa film lama masih memiliki rating tinggi dan jumlah votes besar. Oleh karena itu, perusahaan tidak hanya perlu berfokus pada film modern, tetapi juga perlu mempertahankan film klasik berkualitas sebagai bagian dari strategi katalog.

Analisis hubungan antara rating IMDb dan jumlah votes menunjukkan bahwa film dengan rating tinggi cenderung memiliki jumlah votes yang besar. Temuan ini menunjukkan bahwa kualitas film dan popularitas film memiliki hubungan yang saling mendukung. Namun, perusahaan tidak dapat menggunakan rating saja sebagai dasar pengambilan keputusan bisnis. Perusahaan perlu mempertimbangkan jumlah votes agar keputusan produksi, promosi, dan rekomendasi film lebih akurat.

Hasil komposisi kategori rating menunjukkan bahwa sebagian besar film berada pada kategori Rating Sedang. Film dengan Rating Tinggi memiliki jumlah yang lebih sedikit dibandingkan kategori lainnya. Kondisi tersebut menunjukkan bahwa film dengan rating tinggi memiliki nilai eksklusif dan dapat dijadikan sebagai film unggulan. Sementara itu, film dengan Rating Sedang dapat digunakan sebagai basis katalog utama karena jumlahnya lebih besar dan tetap memiliki kualitas yang layak untuk ditawarkan kepada pengguna.

Berdasarkan kesimpulan tersebut, penulis memberikan beberapa rekomendasi bisnis. Rekomendasi pertama adalah rumah produksi, platform film, atau layanan streaming perlu memprioritaskan produksi dan akuisisi film pada genre Drama. Genre Drama memiliki jumlah kemunculan tertinggi dalam dataset sehingga genre ini memiliki peluang besar untuk menarik minat penonton.

Perusahaan dapat mengembangkan film Drama dengan variasi subgenre, seperti drama keluarga, drama kriminal, drama romantis, dan drama sejarah agar produk film lebih beragam.

Rekomendasi kedua adalah perusahaan perlu memperkuat produksi dan promosi pada genre Comedy, Crime, Action, dan Adventure. Genre-genre tersebut memiliki jumlah kemunculan tinggi setelah Drama. Perusahaan dapat menjadikan genre tersebut sebagai fokus pengembangan film karena genre tersebut memiliki potensi pasar yang luas. Strategi ini dapat dilakukan melalui produksi film baru, pembelian lisensi film populer, atau promosi khusus berdasarkan genre.

Rekomendasi ketiga adalah perusahaan perlu membuat strategi promosi berbasis genre. Perusahaan dapat membuat kampanye promosi seperti “Drama Terbaik Minggu Ini”, “Film Action Populer”, “Crime Movie Collection”, atau “Adventure Movie Recommendation”. Strategi promosi berbasis genre dapat membantu pengguna menemukan film sesuai minatnya dan dapat meningkatkan keterlibatan pengguna terhadap katalog film.

Rekomendasi keempat adalah perusahaan perlu menggunakan kombinasi rating IMDb dan jumlah votes dalam menentukan film unggulan. Perusahaan tidak sebaiknya hanya memilih film berdasarkan rating tertinggi. Perusahaan perlu memilih film yang memiliki rating tinggi dan jumlah votes besar karena kombinasi tersebut menunjukkan kualitas dan popularitas film. Strategi ini dapat membantu perusahaan menentukan film yang layak dipromosikan sebagai film utama.

Rekomendasi kelima adalah perusahaan perlu menempatkan film dengan Rating Tinggi sebagai film premium atau film unggulan. Film dengan rating 8,0 sampai 10 dapat dimasukkan ke dalam kategori “Film Pilihan Terbaik”, “Top Rated Movies”, atau “Rekomendasi Utama”. Strategi ini dapat meningkatkan daya tarik platform karena pengguna dapat menemukan film berkualitas tinggi secara lebih mudah.

Secara keseluruhan, rekomendasi utama dari laporan ini adalah perusahaan perlu memperbanyak produksi, akuisisi, dan promosi film pada genre Drama, Comedy, Crime, Action, dan Adventure. Perusahaan juga perlu menjadikan rating dan jumlah votes sebagai dasar dalam memilih film unggulan. Dengan strategi tersebut, perusahaan dapat mengelola katalog film secara lebih tepat, meningkatkan daya tarik film, dan menyusun rekomendasi film yang lebih relevan bagi pengguna.

DAFTAR PUSTAKA

IMDb Developer. (2026, April 18). *IMDb Non-Commercial Datasets*.


<https://developer.imdb.com/non-commercial-datasets/>

Nunes, T. A. (2026). *IMDb Top 5000 Movies*.

<https://www.kaggle.com/datasets/tiagoadrianunes/imdb-top-5000-movies>

LAMPIRAN-LAMPIRAN

1. Visualisasi tambahan



2. Potongan kode Python dari notebook

```
1 !nvidia-smi
```

```
Fri Jun 5 12:36:57 2026
```

NVIDIA-SMI 580.82.07				Driver Version: 580.82.07				CUDA Version: 13.0			
GPU	Name	Persistence-M	Bus-Id	Disp.A	Volatile	Uncorr.	ECC				
Fan	Temp	Pwr:Usage/Cap	Memory-Usage	GPU-Util	Compute M.	MIG M.					
0	Tesla T4	Off	00000000:00:04.0	Off	0						
N/A	37C	11W / 70W	0MiB / 15360MiB	0%	Default	N/A					

Processes:											
GPU	GI	CI	PID	Type	Process name	GPU Memory					
	ID	ID				Usage					
No running processes found											

```
1 # Membaca Dataset csv
2 movie = pd.read_csv("Top_5000_IMDB.csv")
3 # Menampilkan 5 data teratas
4 movie.head()
```

```

1 movie.shape
2 # Menampilkan jumlah baris dan kolom dataset
3 print(f"Jumlah Kolom: {movie.shape[1]}")
4 print(f"Jumlah baris: {movie.shape[0]}")

```

```

Jumlah Kolom: 12
Jumlah baris: 5000

```

```

1 # Menampilkan nama-nama kolom
2 movie.columns

```

```

Index(['tconst', 'primaryTitle', 'startYear', 'rank', 'averageRating',
       'numVotes', 'runtimeMinutes', 'directors', 'writers', 'genres',
       'IMDbLink', 'Title_IMDb_Link'],
      dtype='object')

```

```

1 # Menampilkan tipe data setiap kolom
2 movie.dtypes

```

```
2 movie.info()
```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5000 entries, 0 to 4999
Data columns (total 12 columns):
#   Column                Non-Null Count  Dtype
---  -
0   tconst                5000 non-null  object
1   primaryTitle          5000 non-null  object
2   startYear             5000 non-null  int64
3   rank                  5000 non-null  int64
4   averageRating         5000 non-null  float64
5   numVotes              5000 non-null  int64
6   runtimeMinutes        5000 non-null  int64
7   directors             5000 non-null  object
8   writers               4975 non-null  object
9   genres                5000 non-null  object
10  IMDbLink              5000 non-null  object
11  Title_IMDb_Link       5000 non-null  object
dtypes: float64(1), int64(4), object(7)
memory usage: 468.9+ KB

```

```
1 # Menampilkan statistik deskriptif untuk semua kolom
2 movie.describe(include="all")
```

```
1 # Mengecek duplikasi dataset
2 print("Jumlah data duplikat: ", movie_object.duplicated().sum())
3
4 # Menampilkan data duplikat jika ada
5 movie_object[movie_object.duplicated()]
```

Jumlah data duplikat: 0

```
      tconst  primaryTitle  startYear  rank  averageRating  numVotes  runtimeMi
```

Menyimpan dan Download Dataset Clean

```
1 # Menyimpan dataset bersih versi lengkap
2 movie.to_csv("Top_5000_IMDb_clean.csv", index=False)
3
4 # Menyimpan dataset objek analisis
5 movie_object.to_csv("Top_5000_IMDb_object_selected.csv", index=False)
6
7 print("Dataset berhasil disimpan")
```

Dataset berhasil disimpan

```
1 # Menampilkan jumlah nilai unik pada setiap kolom
2 movie.nunique()
```

```
1 # Mengecek jumlah missing value pada setiap kolom
2 movie.isnull().sum()
```

```
1 # Mengubah nilai kosong atau hanya berisi spasi pada kolom writers menjadi NaN
2 movie["writers"] = movie["writers"].replace(r"^\s*$", np.nan, regex=True)
3
4 # Mengisi missing value pada kolom writers dengan teks 'unamed' sesuai arahan dosen
5 movie["writers"] = movie["writers"].fillna("unamed")
6
7 # Mengecek ulang missing value
8 movie.isnull().sum()
```

```
1 # Mengecek duplikasi dataset
2 print("Jumlah data duplikat: ", movie.duplicated().sum())
3
4 # Menampilkan data duplikat jika ada
5 movie[movie.duplicated()]
```

```
1 # Boxplot untuk melihat kemungkinan outlier pada rating
2 plt.figure(figsize=(8, 5))
3 sns.boxplot(x=movie["averageRating"])
4 plt.title("Boxplot Average Rating")
5 plt.xlabel("Average Rating")
6 plt.show()

1 # Boxplot untuk melihat kemungkinan outlier pada durasi film
2 plt.figure(figsize=(8, 5))
3 sns.boxplot(x=movie["runtimeMinutes"])
4 plt.title("Boxplot Runtime Minutes")
5 plt.xlabel("Runtime Minutes")
6 plt.show()
```

```

1 # Menentukan kolom numerik yang akan divalidasi outlier-nya
2 outlier_columns = ["averageRating", "runtimeMinutes"]
3
4 # Membuat fungsi untuk menghitung outlier menggunakan metode IQR
5 def hitung_outlier_iqr(data, column):
6     # Menghitung Q1 atau kuartil pertama
7     Q1 = data[column].quantile(0.25)
8
9     # Menghitung Q3 atau kuartil ketiga
10    Q3 = data[column].quantile(0.75)
11
12    # Menghitung nilai IQR
13    IQR = Q3 - Q1
14
15    # Menentukan batas bawah outlier
16    lower_bound = Q1 - (1.5 * IQR)
17
18    # Menentukan batas atas outlier
19    upper_bound = Q3 + (1.5 * IQR)
20
21    # Mengambil data yang berada di bawah batas bawah
22    outlier_q1 = data[data[column] < lower_bound].copy()
23
24    # Mengambil data yang berada di atas batas atas
25    outlier_q3 = data[data[column] > upper_bound].copy()
26
27    # Membuat ringkasan hasil perhitungan outlier
    . . .

```

```

28     hasil = {
29         "Kolom": column,
30         "Q1": Q1,
31         "Q3": Q3,
32         "IQR": IQR,
33         "Lower Bound": lower_bound,
34         "Upper Bound": upper_bound,
35         "Outlier Sisi Q1": len(outlier_q1),
36         "Outlier Sisi Q3": len(outlier_q3),
37         "Total Outlier": len(outlier_q1) + len(outlier_q3)
38     }
39
40     # Mengembalikan ringkasan dan detail outlier
41     return hasil, outlier_q1, outlier_q3
42
43
44 # Membuat list untuk menyimpan ringkasan outlier
45 summary_outlier = []
46
47 # Membuat dataframe kosong untuk menyimpan detail record outlier
48 detail_outlier = pd.DataFrame()
49
50 # Melakukan perulangan untuk setiap kolom numerik
51 for col in outlier_columns:
52     # Menghitung outlier pada kolom tertentu
53     hasil, outlier_q1, outlier_q3 = hitung_outlier_iqr(movie, col)
54     # Mengembalikan hasil perhitungan ke daftar hasil

```

```

54
55     # Menambahkan hasil ringkasan ke dalam list
56     summary_outlier.append(hasil)
57
58     # Memberi keterangan pada outlier sisi Q1
59     outlier_q1["kolom_outlier"] = col
60     outlier_q1["posisi_outlier"] = "Sisi Q1 / Lower Outlier"
61
62     # Memberi keterangan pada outlier sisi Q3
63     outlier_q3["kolom_outlier"] = col
64     outlier_q3["posisi_outlier"] = "Sisi Q3 / Upper Outlier"
65
66     # Menggabungkan semua record outlier
67     detail_outlier = pd.concat([detail_outlier, outlier_q1, outlier_q3])
68
69 # Mengubah ringkasan outlier menjadi dataframe
70 summary_outlier_df = pd.DataFrame(summary_outlier)
71
72 # Menampilkan ringkasan hasil outlier
73 summary_outlier_df

```



```

1 # Histogram distribusi rating film
2 plt.figure(figsize=(10, 5))
3 sns.histplot(movie["averageRating"], bins=20, kde=True)
4 plt.title("Distribusi Average Rating Film IMDb")
5 plt.xlabel("Average Rating")
6 plt.ylabel("Jumlah Film")
7 plt.show()

1 # Membuat dataset untuk Looker Studio
2 movie_looker = movie.copy()
3
4 # Kolom dasar yang tetap dipertahankan
5 base_columns = [
6     "tconst",
7     "primaryTitle",
8     "startYear",
9     "rank",
10    "averageRating",
11    "numVotes",
12    "runtimeMinutes",
13    "directors",
14    "writers",
15    "genres"
16 ]
17
18 # Membuat data genre
19 movie_genre = movie_looker[base_columns].copy()
20 movie_genre["attribute_type"] = "genre"
21 movie_genre["attribute_name"] = movie_genre["genres"].str.split(",")
22
23 # Membuat data director
24 movie_director = movie_looker[base_columns].copy()
25 movie_director["attribute_type"] = "director"
26 movie_director["attribute_name"] = movie_director["directors"].str.split(",")

```

```

27
28 # Membuat data writer
29 movie_writer = movie_looker[base_columns].copy()
30 movie_writer["attribute_type"] = "writer"
31 movie_writer["attribute_name"] = movie_writer["writers"].str.split(",")
32
33 # Menggabungkan genre, director, dan writer dalam satu dataset
34 movie_looker = pd.concat(
35     [movie_genre, movie_director, movie_writer],
36     ignore_index=True
37 )
38
39 # Memisahkan nilai dalam list menjadi baris terpisah
40 movie_looker = movie_looker.explode("attribute_name")
41
42 # Membersihkan spasi pada nama atribut
43 movie_looker["attribute_name"] = movie_looker["attribute_name"].str.strip()
44
45     1 # Menentukan atribut/kolom yang dipakai sebagai objek analisis
46     2 selected_columns = [
47         3     "tconst",
48         4     "primaryTitle",
49         5     "startYear",
50         6     "rank",
51         7     "averageRating",
52         8     "numVotes",
53         9     "runtimeMinutes",
54     10     "directors",
55     11     "writers",
56     12     "genres",
57     13     "attribute_type",
58     14     "attribute_name"
59     15 ]
60
61 # Membentuk dataframe baru berdasarkan atribut yang dipilih
62 movie_object = movie_looker[selected_columns].copy()
63
64 # Menampilkan hasil seleksi objek data
65 movie_object.head(10)

```

```
1 # Menampilkan jumlah kolom dan baris pada objek data terpilih
2 print(f"Jumlah kolom objek data: {movie_object.shape[1]}")
3 print(f"Jumlah baris objek data : {movie_object.shape[0]}")
```

Jumlah kolom objek data: 12
Jumlah baris objek data : 31335

```
1 # Membuat data unik agar setiap film hanya dihitung satu kali
2 movie_unique = movie_object.drop_duplicates(subset="tconst").copy()
3
4 # Merapikan index setelah menghapus duplikasi film
5 movie_unique = movie_unique.reset_index(drop=True)
6
7 # Specs berisi fitur/atribut numerik yang dapat digunakan untuk analisis
8 Specs = movie_unique[["startYear", "rank", "numVotes", "runtimeMinutes"]].copy()
9
10 # Score berisi target/nilai yang ingin dianalisis
11 Score = movie_unique[["averageRating"]].copy()
12
13 # Menampilkan 5 data awal Specs
14 Specs.head()
```

```
1 # Visualisasi korelasi fitur numerik dengan heatmap
2 plt.figure(figsize=(10, 6))
3 sns.heatmap(correlation_matrix, annot=True, fmt=".2f")
4 plt.title("Heatmap Korelasi Fitur Numerik IMDb")
5 plt.show()
```

```
1 # Mengecek duplikasi dataset
2 print("Jumlah data duplikat: ", movie_object.duplicated().sum())
3
4 # Menampilkan data duplikat jika ada
5 movie_object[movie_object.duplicated()]
```

```
1 # Menyimpan dataset bersih versi lengkap
2 movie.to_csv("Top_5000_IMDb_clean.csv", index=False)
3
4 # Menyimpan dataset objek analisis
5 movie_object.to_csv("Top_5000_IMDb_object_selected.csv", index=False)
6
7 print("Dataset berhasil disimpan")
```
